PONTIFÍCIA UNIVERSIDADE CATÓLICA DE CAMPINAS
ENGENHARIA DE SOFTWARE
12563 - PROJETO INTEGRADOR VI - ENGENHARIA DE SOFTWARE

CLASSIFICAÇÃO INTELIGENTE DE CONTEÚDO WEB PARA CONTROLE DE ACESSO EM NAVEGADORES

24002529 EDUARDA LUIZA PINHEIRO NEPOMUCENO
24008214 JEAN YUKI KIMURA
24014979 JHENIFER LAÍS BARBOSA
24019083 JOÃO PEDRO DUARTE GIATTI

ORIENTADORA: SÍLVIA CRISTINA DE MATOS SOARES

CAMPINAS
2º SEMESTRE DE 2026

RESUMO

O acesso frequente de crianças e adolescentes à internet por meio de computadores e navegadores torna relevante o desenvolvimento de mecanismos capazes de identificar e reduzir a exposição a conteúdos potencialmente inadequados. Neste semestre, este projeto propõe o desenvolvimento e a validação de um sistema executado em nível de máquina, associado ao uso de um navegador, capaz de obter o conteúdo textual e as imagens das páginas acessadas e submetê-los a modelos de inteligência artificial para classificação automática, seguindo dois caminhos técnicos complementares: processamento de linguagem natural, para o conteúdo textual, e visão computacional, para o conteúdo visual. Os modelos serão treinados ou ajustados (*fine-tuned*) pela equipe para classificar conteúdos em categorias previamente definidas, permitindo que um mecanismo de políticas consolide as classificações e determine se determinado conteúdo deve ser permitido ou bloqueado. O sistema também deverá registrar informações relevantes sobre as classificações e ações realizadas, de modo a possibilitar a apresentação de estatísticas e histórico por meio de uma interface de acompanhamento. O escopo deste semestre está concentrado na construção e validação dos motores de classificação textual e de imagem e de sua aplicação em nível de máquina, não contemplando ainda a implementação de um *gateway* de rede ou a identificação de usuários por endereço IP. Como evolução planejada para os semestres seguintes, o núcleo desenvolvido será integrado a uma infraestrutura baseada em Raspberry Pi, permitindo a aplicação centralizada de políticas a diferentes dispositivos de uma rede doméstica e, posteriormente, a expansão da solução para outros cenários de controle e segurança digital. Espera-se, ao final deste semestre, obter um protótipo funcional e mensurável, com suas métricas de desempenho e limitações técnicas devidamente documentadas.

Palavras-chave: Inteligência Artificial. Segurança digital. Controle parental. Classificação de conteúdo. Navegadores. Processamento de linguagem natural. Visão computacional.

SUMÁRIO

1	INTRODUÇÃO	4
2	OBJETIVOS	8
2.1	Objetivo Geral	8
2.2	Objetivos Específicos	8
3	REPRESENTANTES DA COMUNIDADE EXTERNA	10
4	FUNDAMENTAÇÃO TEÓRICA	11
5	LEVANTAMENTO E ANÁLISE DE REQUISITOS	12
5.1	Requisitos Funcionais	12
5.2	Requisitos Não Funcionais	19
5.3	Requisitos Específicos para Inteligência Artificial	21
5.3.1	Modelo de Processamento de Linguagem Natural (Texto)	21
5.3.2	Modelo de Visão Computacional (Imagens)	22
6	BENCHMARKING	24
7	DEFINIÇÃO DAS PERSONAS	26
7.1	Persona 1 – Renata Souza, a Mãe Vigilante	26
7.2	Persona 2 – Dona Marlene, Responsável por um Lar com Várias Crianças	27
7.3	Persona 3 – Caio “Modo Anônimo”, o Adversário	28
8	PROTÓTIPOS DAS INTERFACES	29
9	MODELO DE DADOS	30
10	ARQUITETURA E TECNOLOGIAS	31
11	DESCRIÇÃO DA SOLUÇÃO TECNOLOGICA ATUAL DO PROJETO	32
11.1	Base de Dados	32
11.2	Pré-processamento dos Dados	32
11.3	Modelos de IA Utilizados	33
11.4	Treinamento e Validação	34
11.5	Métricas de Avaliação	35
12	TESTES E VALIDAÇÃO DO SISTEMA	37
13	GESTÃO DO PROJETO	38

14 RESULTADOS E DISCUSSÃO 39

15 CONCLUSÃO E TRABALHOS FUTUROS 40

16 ACEITE FINAL DO PROJETO 41

17 REFERÊNCIAS 42

REFERÊNCIAS 43

1 INTRODUÇÃO

O acesso à internet por crianças e adolescentes ocorre, cada vez mais, por meio de navegadores instalados em computadores e outros dispositivos de uso pessoal. Embora a internet ofereça importantes recursos para educação, comunicação e entretenimento, a variedade e a velocidade de publicação de conteúdos também dificultam a identificação manual de materiais potencialmente inadequados.

As soluções tradicionais de controle de acesso frequentemente dependem de listas de bloqueio, categorias previamente cadastradas ou configurações realizadas individualmente em cada dispositivo. Essas abordagens podem apresentar limitações diante de páginas novas, conteúdos dinâmicos e situações em que um mesmo domínio disponibiliza materiais de naturezas distintas. Nesse contexto, técnicas de inteligência artificial podem ser utilizadas para analisar o conteúdo textual e o conteúdo visual (imagens) de uma página e estimar a quais categorias de conteúdo ela pertence, oferecendo uma camada adicional de decisão.

Este projeto tem como foco o desenvolvimento, neste semestre, de um sistema em nível de máquina voltado à análise do conteúdo textual e do conteúdo visual (imagens) de páginas acessadas por meio de um navegador. A proposta consiste em obter o conteúdo textual e as imagens disponíveis durante a navegação, submetê-los a modelos de inteligência artificial treinados ou ajustados pela equipe — um voltado ao texto e outro às imagens — e produzir classificações associadas a categorias previamente definidas. A partir dessas classificações, um mecanismo de políticas poderá determinar se o conteúdo deve ser permitido ou bloqueado de acordo com as regras estabelecidas para o cenário de uso.

A arquitetura proposta separa a responsabilidade de classificação da responsabilidade de decisão. Os modelos de inteligência artificial deverão responder à pergunta “que tipo de conteúdo está presente?” — cada um a partir de sua modalidade (texto ou imagem) —, enquanto o mecanismo de políticas deverá responder “esse conteúdo é permitido para este contexto?”, consolidando as classificações recebidas. Essa separação permite que as mesmas classificações sejam utilizadas por diferentes conjuntos de regras e possibilita a evolução posterior da solução para outros ambientes.

Para este semestre, o projeto seguirá dois caminhos técnicos complementares de inteligência artificial: a análise textual, com a utilização de técnicas de processamento de linguagem natural (PLN), e a análise visual, com a utilização de técnicas de visão computacional aplicadas às imagens presentes nas páginas. Os dois modelos serão treinados ou ajustados (*fine-tuned*) a partir de dados apropriados para as categorias definidas pela equipe. Suas avaliações serão realizadas por meio de métricas como precisão, *recall*, F1-*score*, taxas de falsos positivos e falsos negativos e tempo de classificação, permitindo medir não apenas a capacidade de classificação de cada modelo, mas também a viabilidade de sua utilização conjunta em um cenário de navegação.

O projeto também poderá disponibilizar uma interface de acompanhamento, na qual informações como classificações realizadas (textuais e de imagem), conteúdos bloqueados e

estatísticas de uso possam ser consultadas. Essa interface tem caráter de apoio ao acompanhamento e à avaliação do protótipo, não constituindo, neste semestre, um painel de administração de uma rede doméstica.

É importante delimitar o escopo desta etapa. O sistema desenvolvido terá como escopo: (i) um mecanismo em nível de máquina associado à navegação por navegador; (ii) a obtenção e o processamento do conteúdo textual e das imagens das páginas acessadas; (iii) um modelo de processamento de linguagem natural e um modelo de visão computacional, treinados ou ajustados pela equipe, para classificação do conteúdo textual e visual, respectivamente, em categorias definidas; (iv) um mecanismo de aplicação de políticas capaz de consolidar as classificações textual e de imagem e de permitir ou bloquear conteúdos de acordo com elas; e (v) o registro e a apresentação de informações necessárias para testes, validação e acompanhamento do sistema.

Não fazem parte do escopo deste semestre: a implementação do Raspberry Pi como *gateway* de rede; a identificação de usuários ou dispositivos por endereço IP em nível de rede; a aplicação centralizada de políticas para múltiplos dispositivos; e a análise do tráfego criptografado ponto a ponto. Também não se pretende garantir o bloqueio absoluto de todo conteúdo inadequado presente na internet. A solução será apresentada como um mecanismo de redução da exposição a conteúdos potencialmente inadequados, considerando as limitações inerentes à obtenção de conteúdo textual e de imagens, ao funcionamento dos navegadores, ao uso de HTTPS e à natureza dinâmica da web.

Evolução planejada do projeto

A solução desenvolvida neste semestre constitui o núcleo inicial de uma proposta de maior abrangência para os semestres seguintes. Como evolução planejada, os motores de classificação textual e de imagem deverão ser integrados a uma infraestrutura baseada em Raspberry Pi, que atuará como ponto central de controle em uma rede doméstica. Nessa etapa futura, será possível associar dispositivos e, posteriormente, usuários ou perfis a políticas específicas e aplicar as decisões de acesso de maneira centralizada.

Em uma etapa posterior, a solução poderá incorporar um painel administrativo voltado a responsáveis, permitindo configurar perfis, políticas e horários, além de acompanhar estatísticas e tentativas de acesso bloqueadas. A arquitetura também poderá ser expandida para cenários além do controle parental, como ambientes educacionais e empresariais, nos quais a classificação inteligente de conteúdo possa auxiliar na redução de riscos de segurança digital.

Círculo Dourado

Para explicitar o propósito do projeto, aplica-se o modelo do Círculo Dourado (*Golden Circle*), de Simon Sinek, estruturado em três camadas: *Why* (por quê), *How* (como) e *What* (o quê).

a) **Why (Por quê):** Acreditamos que responsáveis devem possuir meios acessíveis de reduzir a exposição de crianças e adolescentes a conteúdos potencialmente inadequados na internet, sem depender exclusivamente de listas estáticas de bloqueio ou de configurações técnicas complexas.

b) **How (Como):** Neste semestre, isso será investigado por meio de um sistema em nível de máquina capaz de analisar o conteúdo textual e o conteúdo visual (imagens) de páginas acessadas no navegador, utilizando um modelo de processamento de linguagem natural e um modelo de visão computacional, treinados ou ajustados pela equipe, para classificá-los segundo categorias previamente definidas. As classificações serão então consolidadas e utilizadas por um mecanismo de políticas para determinar a ação de acesso.

c) **What (O quê):** O resultado deste semestre será um protótipo funcional de classificação e controle de conteúdo textual e visual em nível de máquina, acompanhado de métricas de avaliação de cada modalidade e, quando aplicável, uma interface para acompanhamento das classificações e bloqueios. Nos semestres seguintes, esse núcleo será integrado a uma infraestrutura de rede baseada em Raspberry Pi, com o objetivo de evoluir para uma solução centralizada de controle de acesso.



Figura 1 – Círculo Dourado

2 OBJETIVOS

2.1 Objetivo Geral

Desenvolver e validar um protótipo em nível de máquina capaz de analisar o conteúdo textual e o conteúdo visual (imagens) de páginas acessadas por meio de um navegador, utilizando um modelo de processamento de linguagem natural e um modelo de visão computacional, treinados ou ajustados (*fine-tuned*) pela equipe, para classificar conteúdos em categorias previamente definidas e aplicar políticas de permissão ou bloqueio a partir da consolidação dessas classificações.

2.2 Objetivos Específicos

a) Pesquisar e selecionar técnicas de processamento de linguagem natural e de visão computacional, bem como modelos de inteligência artificial adequados à classificação de conteúdo textual e visual de páginas web, considerando as restrições de execução e resposta esperadas para um sistema em nível de máquina;

b) Construir, preparar e documentar bases de dados (textual e de imagens) para treinamento, validação e teste dos modelos, definindo categorias de conteúdo e procedimentos de pré-processamento compatíveis com cada modalidade;

c) Treinar ou ajustar (*fine-tune*) um modelo de processamento de linguagem natural e um modelo de visão computacional para classificar, respectivamente, o conteúdo textual e as imagens das páginas nas categorias definidas, buscando reduzir a dependência de listas estáticas de sites;

d) Desenvolver o mecanismo em nível de máquina responsável por obter o conteúdo textual e as imagens das páginas acessadas pelo navegador e encaminhá-los aos respectivos classificadores, respeitando as limitações técnicas impostas pelo funcionamento da web e pelo uso de conexões criptografadas;

e) Desenvolver um mecanismo de políticas que utilize e consolide as classificações textual e de imagem produzidas pela inteligência artificial para determinar se determinado conteúdo deve ser permitido ou bloqueado, mantendo separadas as responsabilidades de classificação e decisão;

f) Implementar, quando aplicável ao protótipo, uma interface de acompanhamento das classificações e ações realizadas, permitindo visualizar informações como conteúdos analisados (por modalidade), bloqueios e estatísticas de uso;

g) Avaliar o desempenho dos classificadores textual e de imagem por meio de métricas como precisão, *recall*, F1-*score*, taxa de falsos positivos, taxa de falsos negativos e

tempo de classificação, analisando os resultados obtidos, isoladamente e em conjunto, e suas limitações;

h) Realizar testes do sistema em diferentes situações de navegação, verificando a integração entre obtenção do conteúdo textual e visual, classificação, consolidação das classificações, aplicação das políticas e registro dos resultados;

i) Identificar e documentar as limitações técnicas, éticas e de privacidade da solução, especialmente aquelas relacionadas ao monitoramento de navegação, à obtenção de conteúdo textual e de imagens, à classificação automatizada e ao uso de dados de navegação;

j) Estabelecer uma base arquitetural que permita, nos semestres seguintes, a integração dos motores de classificação textual e de imagem a uma infraestrutura de rede baseada em Raspberry Pi e a evolução da solução para aplicação centralizada de políticas em múltiplos dispositivos.

3 REPRESENTANTES DA COMUNIDADE EXTERNA

Caracterizar a extensão (62 horas de extensão) - são as pessoas que participarão da definição, das entrevistas, da definição dos requisitos, da validação dos protótipos e da validação final do projeto).

Nome, contato (e-mail) e cargo do profissional/pessoa e o nome e CNPJ da organização onde ele(a) atua (2 a 5 profissionais).

4 FUNDAMENTAÇÃO TEÓRICA

Apresentar os conceitos teóricos relacionados à tecnologia atual e Engenharia de Software que embasam o projeto.

Incluir a definição das técnicas/ferramentas/algoritmos etc. das tecnologias atuais utilizadas.

5 LEVANTAMENTO E ANÁLISE DE REQUISITOS

5.1 Requisitos Funcionais

Os requisitos funcionais são descritos no formato de histórias de usuário da metodologia ágil (*"Eu, enquanto <quem>, quero <o quê>, para <por quê>"*). O Quadro 1 resume os requisitos e suas prioridades; o detalhamento de cada um segue logo após.

Código	**Nome**	**Prioridade**
RF001	Captura de conteúdo das páginas	Essencial
RF002	Pré-processamento do conteúdo textual	Essencial
RF003	Classificação textual (PLN)	Essencial
RF004	Nível de confiança da classificação textual	Essencial
RF005	Pré-processamento de imagens	Essencial
RF006	Classificação de imagens (visão computacional)	Essencial
RF007	Nível de confiança da classificação de imagem	Essencial
RF008	Consolidação das classificações de texto e imagem	Essencial
RF009	Aplicação do mecanismo de políticas	Essencial
RF010	Configuração de regras de política por categoria	Importante
RF011	Bloqueio de acesso com mensagem informativa	Essencial
RF012	Registro (log) das classificações	Essencial
RF013	Consulta do histórico de classificações e bloqueios	Importante
RF014	Estatísticas de uso	Importante
RF015	Início e pausa do monitoramento	Importante

Tabela 1 – Requisitos Funcionais

Identificador	**RF001**
Nome	Captura de conteúdo das páginas
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero que o sistema obtenha o conteúdo textual e as imagens das páginas acessadas durante a navegação, para que esse conteúdo possa ser analisado e classificado.
Atores	• Usuário monitorado (navega pelas páginas) • Extensão do navegador (coleta o conteúdo)
Informações / Dados	• **Entrada:** URL/domínio e DOM da página acessada • **Saída:** texto bruto da página, lista de imagens (origem e dimensões) e data/hora da captura

Identificador	**RF002**
Nome	Pré-processamento do conteúdo textual
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero que o texto obtido seja limpo e normalizado antes da classificação, para que o classificador receba conteúdo livre de ruído e produza resultados mais precisos.
Atores	• Módulo de pré-processamento textual (sistema)
Informações / Dados	• **Entrada:** texto bruto (com marcações HTML, menus, rodapés e *scripts*) • **Saída:** texto limpo e normalizado • **Parâmetros:** tamanho mínimo e máximo de texto (ex.: mínimo de 50 palavras; máximo de 512 *tokens*)

Identificador	**RF003**
Nome	Classificação textual (PLN)
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero que o texto pré-processado seja classificado por um modelo de PLN em categorias previamente definidas, para identificar conteúdo textual potencialmente inadequado.
Atores	• Módulo de PLN (sistema)
Informações / Dados	• **Entrada:** texto pré-processado • **Saída:** categoria textual atribuída e versão do modelo utilizada • **Categorias:** definidas pela equipe (ex.: seguro, sexual, violência, drogas, jogos de azar, discurso de ódio)

Identificador	**RF004**
Nome	Nível de confiança da classificação textual
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero que cada classificação textual tenha um nível de confiança associado, para que a decisão do sistema leve em conta a certeza do modelo de PLN.
Atores	• Módulo de PLN (sistema) • Mecanismo de políticas (consome o *score*)
Informações / Dados	• **Entrada:** saída do modelo de PLN • **Saída:** *score* de confiança no intervalo [0, 1] associado à categoria atribuída

Identificador	**RF005**
Nome	Pré-processamento de imagens
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero que as imagens obtidas sejam redimensionadas, normalizadas e filtradas antes da classificação, para que apenas imagens relevantes sejam analisadas e o tempo de resposta seja adequado.
Atores	• Módulo de pré-processamento de imagens (sistema)
Informações / Dados	• **Entrada:** imagens brutas da página • **Saída:** imagens redimensionadas e normalizadas no formato de entrada do modelo • **Critérios de descarte:** ícones e imagens de interface; dimensão mínima (ex.: 100×100 px); limite de imagens por página (ex.: as 10 a 20 maiores) • **Parâmetro:** tamanho de entrada do modelo (ex.: 224×224 px)

Identificador	**RF006**
Nome	Classificação de imagens (visão computacional)
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero que as imagens pré-processadas sejam classificadas por um modelo de visão computacional em categorias previamente definidas, para identificar conteúdo visual potencialmente inadequado.
Atores	• Módulo de visão computacional (sistema)
Informações / Dados	• **Entrada:** imagens pré-processadas • **Saída:** categoria visual atribuída a cada imagem e versão do modelo utilizada • **Categorias:** definidas pela equipe, com mapeamento para as categorias textuais

Identificador	**RF007**
Nome	Nível de confiança da classificação de imagem
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero que cada classificação de imagem tenha um nível de confiança associado, para que a decisão do sistema leve em conta a certeza do modelo de visão computacional.
Atores	• Módulo de visão computacional (sistema) • Mecanismo de políticas (consome o *score*)
Informações / Dados	• **Entrada:** saída do modelo de visão computacional • **Saída:** *score* de confiança no intervalo [0, 1] associado à categoria atribuída

Identificador	**RF008**
Nome	Consolidação das classificações de texto e imagem
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero que as classificações textual e de imagem de uma mesma página sejam consolidadas em uma decisão única, com critério de precedência para os casos de divergência, para que o mecanismo de políticas receba um resultado coerente.
Atores	• Módulo de consolidação (sistema)
Informações / Dados	• **Entrada:** categoria e *score* textuais; categoria(s) e *score*(s) de imagem • **Regra de precedência:** em caso de divergência, prevalece a classificação associada à ação mais restritiva da política (bloquear $>$ alertar $>$ permitir) • **Saída:** decisão consolidada (categoria, *score* e modalidade de origem)

Identificador	**RF009**
Nome	Aplicação do mecanismo de políticas
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero que um mecanismo de políticas determine, a partir da decisão consolidada, se o conteúdo deve ser permitido, bloqueado ou alertado, para que a navegação do usuário seja controlada de acordo com as regras definidas.
Atores	• Mecanismo de políticas (sistema) • Responsável (define as regras)
Informações / Dados	• **Entrada:** decisão consolidada (RF008) e regras por categoria (RF010) • **Parâmetros:** limiares de confiança (ex.: $\geq 0{,}80$ bloqueia; entre 0,50 e 0,80 alerta; $<$ 0,50 permite; limiar de bloqueio menor nas categorias sensíveis) • **Saída:** ação a ser tomada (permitir, bloquear ou alertar)

Identificador	**RF010**
Nome	Configuração de regras de política por categoria
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero configurar a ação (permitir, bloquear ou alertar) para cada categoria de conteúdo, para adequar a proteção ao perfil do usuário monitorado.
Atores	• Responsável
Informações / Dados	• **Entrada:** categoria, ação desejada e, opcionalmente, limiar de confiança • **Saída:** conjunto de regras persistido e aplicado pelo mecanismo de políticas

Identificador	**RF011**
Nome	Bloqueio de acesso com mensagem informativa
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero que o acesso seja bloqueado e uma mensagem informativa seja exibida ao usuário quando a política determinar o bloqueio, para impedir a exposição ao conteúdo e deixar claro o motivo da restrição.
Atores	• Usuário monitorado (visualiza a mensagem) • Extensão do navegador (executa o bloqueio)
Informações / Dados	• **Entrada:** ação “bloquear”, URL da página e categoria atribuída • **Saída:** página de bloqueio com mensagem informativa

Identificador	**RF012**
Nome	Registro (log) das classificações
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero que cada classificação realizada seja registrada, para permitir o acompanhamento e a auditoria das decisões do sistema.
Atores	• Módulo de registro (sistema) • Responsável (consulta os registros)
Informações / Dados	• **Campos:** URL/domínio, modalidade (texto e/ou imagem), categoria atribuída, nível de confiança, ação tomada, data/hora e versão do modelo • **Observação:** o conteúdo integral (texto e imagens) não deve ser armazenado além do necessário (RNF003)

Identificador	**RF013**
Nome	Consulta do histórico de classificações e bloqueios
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero consultar o histórico de classificações e bloqueios em uma interface de acompanhamento, para saber quais conteúdos foram analisados e quais ações foram tomadas.
Atores	• Responsável
Informações / Dados	• **Entrada:** filtros opcionais (período, categoria, ação, modalidade, domínio) • **Saída:** lista de registros de classificação conforme os filtros

Identificador	**RF014**
Nome	Estatísticas de uso
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero visualizar estatísticas de uso na interface de acompanhamento, para entender o padrão de navegação e a atuação do sistema ao longo do tempo.
Atores	• Responsável
Informações / Dados	• **Entrada:** período consultado (ex.: 24 h, 7 dias, 30 dias ou personalizado) • **Saída:** total de páginas analisadas, distribuição por categoria e percentual bloqueado por modalidade

Identificador	**RF015**
Nome	Início e pausa do monitoramento
Descrição Geral	Eu, enquanto responsável pelo monitoramento, quero iniciar ou pausar o monitoramento, para controlar quando a análise da navegação está ativa.
Atores	• Responsável • Usuário monitorado (afetado pelo estado do monitoramento)
Informações / Dados	• **Entrada:** comando de iniciar ou pausar e, se aplicável, autenticação do responsável (ex.: PIN) • **Saída:** estado atual (ativo ou pausado) e registro da alteração com data/hora

5.2 Requisitos Não Funcionais

Os requisitos não funcionais descrevem atributos de qualidade do sistema, organizados a partir de categorias inspiradas na norma ISO/IEC 25010.

Código	Categoria	Descrição	Prioridade
RNF001	Desempenho	A classificação textual e a classificação de imagem de uma página devem ser concluídas em tempo compatível com a experiência de navegação, com metas numéricas a serem validadas experimentalmente durante a avaliação dos modelos (ver RIA005 e RIC005).	Essencial
RNF002	Segurança	O conteúdo textual, as imagens coletadas e os registros de navegação armazenados localmente devem ser protegidos contra acesso não autorizado (ex.: permissões de arquivo restritas).	Essencial
RNF003	Privacidade	O sistema deve minimizar a coleta e a retenção de dados de navegação (textuais e de imagem) ao estritamente necessário para classificação, auditoria e apresentação de estatísticas, em conformidade com a LGPD.	Essencial
RNF004	Usabilidade	A interface de acompanhamento deve apresentar as informações de forma clara e compreensível para usuários sem conhecimento técnico avançado.	Importante
RNF005	Confiabilidade	O sistema deve continuar operando em modo degradado (ex.: aplicando uma política padrão) em caso de falha de qualquer um dos módulos de classificação (textual ou de imagem), evitando bloquear indevidamente toda a navegação.	Importante
RNF006	Manutenibilidade	A arquitetura deve manter separadas as responsabilidades de classificação textual (PLN), classificação de imagem (visão computacional) e de aplicação de políticas, permitindo evolução e substituição independente de cada módulo.	Essencial

Código	Categoria	Descrição	Prioridade
RNF007	Escalabilidade	O sistema deve ser projetado de modo a permitir, em semestres futuros, sua integração a uma infraestrutura baseada em Raspberry Pi sem redesenho dos motores de classificação textual e de imagem.	Importante
RNF008	Compatibilidade	O sistema deve ser compatível com pelo menos um navegador amplamente utilizado (a definir pela equipe, ex.: Chrome/Chromium ou Firefox).	Essencial
RNF009	Auditabilidade	Todos os registros de log gerados devem ser íntegros e rastreáveis, permitindo auditoria posterior das decisões tomadas pelo sistema.	Importante

Tabela 2 – Requisitos Não Funcionais

5.3 Requisitos Específicos para Inteligência Artificial

5.3.1 Modelo de Processamento de Linguagem Natural (Texto)

Código	Descrição	Prioridade
RIA001	O modelo de PLN deve atingir acurácia mínima de *85%* no conjunto de teste, considerando as categorias de conteúdo estabelecidas pela equipe.	Essencial
RIA002	O modelo deve atingir F1-*score* mínimo de *0,80* ($\geq$ 0,85 nas categorias sensíveis) por categoria, priorizando o *recall* nas categorias de conteúdo sensível.	Essencial
RIA003	A taxa de falsos negativos para categorias sensíveis (conteúdo potencialmente inadequado) deve ser inferior a *10%* (*recall* $\geq$ 0,90), priorizando a redução de exposição em detrimento de bloqueios excessivos.	Essencial
RIA004	A taxa de falsos positivos deve ser mantida abaixo de *10%*, de modo a preservar a usabilidade do sistema e evitar bloqueios indevidos de conteúdo legítimo.	Importante
RIA005	O tempo de inferência do modelo para o texto de uma única página deve ser inferior a *500 milissegundos*, em hardware de referência estabelecido pela equipe.	Essencial

Código	Descrição	Prioridade
RIA006	O modelo deve ser treinado ou ajustado (*fine-tuned*) a partir de uma base de dados textual rotulada, documentada quanto à origem, ao volume e à distribuição entre categorias.	Essencial
RIA007	O processo de treinamento deve utilizar conjuntos distintos de treino, validação e teste, evitando vazamento de dados (*data leakage*) entre eles.	Essencial
RIA008	O modelo utilizado em cada classificação textual registrada deve ser identificável por versão, permitindo rastrear qual versão gerou determinado resultado.	Importante
RIA009	O sistema deve registrar o nível de confiança (*score*) de cada classificação textual, possibilitando a definição de limiares (*thresholds*) distintos por categoria no mecanismo de políticas.	Importante
RIA010	O desempenho do modelo diante de conteúdos ambíguos ou com pouco texto disponível deve ser avaliado e documentado, junto às limitações identificadas.	Importante
RIA011	O sistema deve permitir a reavaliação periódica do modelo de PLN com novos dados, sem comprometer a disponibilidade do mecanismo de classificação durante a atualização.	Desejável

Tabela 3 – Requisitos Específicos do Modelo de Processamento de Linguagem Natural

5.3.2 Modelo de Visão Computacional (Imagens)

Código	Descrição	Prioridade
RIC001	O modelo de visão computacional deve atingir acurácia mínima de *90%* no conjunto de teste, considerando as categorias de conteúdo estabelecidas pela equipe.	Essencial
RIC002	O modelo deve atingir F1-*score* mínimo de *0,80* ($\geq$ 0,85 nas categorias sensíveis) por categoria, priorizando o *recall* nas categorias de conteúdo visual sensível.	Essencial
RIC003	A taxa de falsos negativos para categorias sensíveis (imagens potencialmente inadequadas) deve ser inferior a *5%* (*recall* $\geq$ 0,95), priorizando a redução de exposição em detrimento de bloqueios excessivos.	Essencial

Código	Descrição	Prioridade
RIC004	A taxa de falsos positivos deve ser mantida abaixo de *5%*, de modo a preservar a usabilidade do sistema e evitar bloqueios indevidos de imagens legítimas.	Importante
RIC005	O tempo de inferência do modelo para uma única imagem deve ser inferior a *300 milissegundos*, em hardware de referência estabelecido pela equipe.	Essencial
RIC006	O modelo deve ser treinado ou ajustado (*fine-tuned*) a partir de uma base de dados de imagens rotulada, documentada quanto à origem, ao volume e à distribuição entre categorias.	Essencial
RIC007	O processo de treinamento deve utilizar conjuntos distintos de treino, validação e teste, evitando vazamento de dados (*data leakage*) entre eles.	Essencial
RIC008	O modelo utilizado em cada classificação de imagem registrada deve ser identificável por versão, permitindo rastrear qual versão gerou determinado resultado.	Importante
RIC009	O sistema deve registrar o nível de confiança (*score*) de cada classificação de imagem, possibilitando a definição de limiares (*thresholds*) distintos por categoria no mecanismo de políticas.	Importante
RIC010	O desempenho do modelo diante de imagens de baixa resolução, parcialmente carregadas ou de conteúdo ambíguo deve ser avaliado e documentado, junto às limitações identificadas.	Importante
RIC011	O sistema deve permitir a reavaliação periódica do modelo de visão computacional com novos dados, sem comprometer a disponibilidade do mecanismo de classificação durante a atualização.	Desejável

Tabela 4 – Requisitos Específicos do Modelo de Visão Computacional

6 BENCHMARKING

O benchmarking compara o ORCA com três soluções de controle parental disponíveis no mercado: Qustodio, Microsoft Family Safety e Net Nanny. A comparação considera funcionalidades de filtragem, análise de conteúdo, aplicação de regras, monitoramento e características técnicas relacionadas aos objetivos do projeto. O objetivo não é afirmar que o ORCA apresenta mais recursos que as soluções existentes, mas identificar diferenças entre as abordagens adotadas e a proposta técnica desenvolvida neste projeto.

Funcionalidade	**ORCA**	**Qustodio**	**Microsoft Family Safety**	**Net Nanny**
Filtragem de sites por categorias	✓	✓	✓	✓
Análise contextual do conteúdo textual em tempo real	✓	–	X	✓
Modelo de processamento de linguagem natural treinado ou ajustado pela equipe	✓	X	X	X
Classificação de imagens por modelo de visão computacional	✓	–	–	–
Modelo de visão computacional treinado ou ajustado pela equipe	✓	X	X	X
Mecanismo próprio para consolidar classificações textuais e visuais	✓	X	X	X
Regras para permitir ou bloquear conteúdo	✓	✓	✓	✓
Bloqueio de sites específicos	✓	✓	✓	✓
Controle de tempo de tela e uso de aplicativos	X	✓	✓	✓
Histórico ou relatórios de atividade	✓	✓	✓	✓
Avaliação dos classificadores por métricas de desempenho	✓	X	X	X
Controle centralizado por gateway Raspberry Pi	X	–	X	X

Tabela 5 – Comparativo entre o ORCA e soluções de controle parental do mercado.

O principal diferencial técnico do ORCA é a proposta de combinar dois classificadores de inteligência artificial: um baseado em processamento de linguagem natural (PLN), voltado à análise do conteúdo textual, e outro baseado em visão computacional, voltado à classificação das imagens presentes nas páginas acessadas pelo navegador. Os modelos serão treinados ou ajustados pela equipe com bases de dados preparadas para as categorias definidas no projeto. Como

as soluções comerciais podem utilizar tecnologias proprietárias, a ausência de documentação pública sobre uma técnica específica não significa que ela não seja utilizada internamente; por isso, os campos sem confirmação foram indicados com um traço.

Outra característica da proposta é a separação entre classificação e decisão. Os classificadores deverão identificar as categorias presentes no texto e nas imagens, enquanto um mecanismo de políticas consolidará os resultados e determinará se o conteúdo deve ser permitido ou bloqueado. Essa arquitetura será avaliada por meio de métricas como precisão, recall, F1-score, taxas de falsos positivos e falsos negativos e tempo de classificação.

As soluções analisadas também oferecem funcionalidades que não fazem parte do escopo atual do ORCA, como controle de tempo de tela e uso de aplicativos. Além disso, a aplicação centralizada de políticas por meio de um gateway Raspberry Pi é uma evolução planejada para os próximos semestres, e não uma funcionalidade prevista para o protótipo deste semestre. Dessa forma, o benchmarking evidencia tanto as capacidades que o ORCA pretende investigar quanto os limites de seu escopo em relação às ferramentas existentes.

7 DEFINIÇÃO DAS PERSONAS

7.1 Persona 1 – Renata Souza, a Mãe Vigilante



- **Nome:** Renata Souza
- **Idade:** 38 anos
- **Sexo:** Feminino
- **Estado Civil:** Casada
- **Ocupação/Trabalho:** Analista financeira, trabalha em regime híbrido (*home office* 3x por semana)
- **Biografia:** Atua na área financeira e gerencia a rotina familiar. Mãe de Lucas (8) e Beatriz (12); o notebook do trabalho e o tablet da casa são compartilhados pelos filhos fora do horário escolar.
- **Hobbies:** Leitura, jardinagem e passar tempo em família.
- **Conhecimento em tecnologia:** Médio.
- **Conhecimento no domínio do negócio:** Alto.
- **Dispositivos que mais utiliza:** Notebook e celular.
- **Objetivos dentro do sistema:** Ter tranquilidade para trabalhar sem precisar ficar ao lado das crianças durante a navegação, entendendo de forma simples quais tipos de conteúdo os filhos estão encontrando e confiando que o sistema toma decisões corretas.
- **Motivos para utilizar o sistema:** Soluções de controle parental tradicionais são complexas ou geram alertas em excesso. O sistema oferece transparência, facilidade de uso e redução de falsos positivos em conteúdos escolares.

7.2 Persona 2 – Dona Marlene, Responsável por um Lar com Várias Crianças



- **Nome:** Marlene da Silva (Dona Marlene)
- **Idade:** 58 anos
- **Sexo:** Feminino
- **Estado Civil:** Viúva
- **Ocupação/Trabalho:** Aposentada; cuida informalmente dos netos e sobrinhos-netos enquanto os pais trabalham
- **Biografia:** Funciona como uma espécie de "creche familiar", recebendo em casa até 5 crianças com idades entre 6 e 14 anos em horários distintos, contando com um único computador e um tablet compartilhados.
- **Hobbies:** Tricô, culinária e cuidar das plantas.
- **Conhecimento em tecnologia:** Baixo.
- **Conhecimento no domínio do negócio:** Médio.
- **Dispositivos que mais utiliza:** Computador de mesa compartilhado.
- **Objetivos dentro do sistema:** Um sistema que funcione no "piloto automático", sem exigir troca de perfil a cada criança, garantindo proteção consistente sem configurações complexas.
- **Motivos para utilizar o sistema:** Necessidade de proteção automática em dispositivos compartilhados por crianças de diferentes faixas etárias, sem exigir conhecimentos técnicos avançados de sua parte.

7.3 Persona 3 – Caio “Modo Anônimo”, o Adversário



- **Nome:** Caio Mendes
- **Idade:** 13 anos
- **Sexo:** Masculino
- **Estado Civil:** Solteiro (Estudante)
- **Ocupação/Trabalho:** Estudante do 8º ano
- **Biografia:** Autoproclamado “especialista em TI” da família. Usa o tablet da casa compartilhado com os pais e irmão mais novo; já alterou configurações de rede por curiosidade para testar limites.
- **Hobbies:** Jogos eletrônicos, vídeos de tecnologia e exploração de softwares.
- **Conhecimento em tecnologia:** Alto para a idade.
- **Conhecimento no domínio do negócio:** Baixo.
- **Dispositivos que mais utiliza:** Tablet e smartphone.
- **Objetivos dentro do sistema:** Acessar conteúdo sem restrição por curiosidade ou para testar os limites do sistema, entendendo como a ferramenta decide o que bloquear.
- **Motivos para testar o sistema:** Representa o caso de uso adversarial essencial para validar os requisitos de segurança, integridade de registros e robustez da arquitetura de IA.

8 PROTÓTIPOS DAS INTERFACES

Print, legível, das interfaces, no arquivo do relatório final .docx e também o link do software utilizado para o design (ex: link do figma, XD etc.).

Não será aceito apenas o link.

Validação/aceite dos protótipos com as pessoas/profissionais da comunidade externa.

9 MODELO DE DADOS

MER para banco de dados relacional ou modelo da estrutura de dados para banco de dados não relacional.

10 ARQUITETURA E TECNOLOGIAS

Descrever a arquitetura geral do sistema, incluindo o diagrama/modelo arquitetural e a integração dos componentes de IA e/ou demais tecnologias atuais do projeto.

Descrever as tecnologias, linguagens, frameworks e bibliotecas utilizadas no desenvolvimento do sistema (frontend, protótipos, backend, banco de dados, cloud etc).

11 DESCRIÇÃO DA SOLUÇÃO TECNOLOGICA ATUAL DO PROJETO

11.1 Base de Dados

Processamento de Linguagem Natural (PLN)

O projeto PI6-ORCA utiliza uma base de dados textual para o desenvolvimento de um modelo de Inteligência Artificial capaz de classificar textos em três categorias: seguro, suicídio e ódio. A solução combina dados de duas fontes principais: o conjunto Boamente e o conjunto TuPyE.

Os dados são consolidados e organizados por meio do pipeline de preparação de dados do projeto. Durante esse processo, os rótulos originais são convertidos para as três classes utilizadas pelo classificador, permitindo que as diferentes fontes sejam integradas em uma estrutura comum.

Após a preparação inicial, os dados são divididos em três conjuntos: treinamento, validação e teste, utilizando a proporção de 70

A divisão inicial registrada contém 40.178 textos, distribuídos da seguinte forma:

- Treinamento: 28.124 textos.
- Validação: 6.027 textos.
- Teste: 6.027 textos.

Durante a execução do treinamento, são aplicadas verificações adicionais para evitar que textos iguais ou equivalentes, após a normalização, apareçam em diferentes conjuntos. Com isso, o treinamento oficial utilizou efetivamente 28.090 textos, enquanto a validação utilizou 6.025 textos. O conjunto de teste permaneceu com 6.027 textos.

A base apresenta um desequilíbrio na quantidade de exemplos por classe, com predominância da categoria “seguro” e menor quantidade de exemplos da categoria “suicídio”. Para reduzir o impacto desse desequilíbrio durante o aprendizado, o treinamento utiliza pesos de classe calculados a partir da frequência de cada categoria.

11.2 Pré-processamento dos Dados

Processamento de Linguagem Natural (PLN)

O pré-processamento tem como objetivo padronizar os textos, reduzir inconsistências e evitar que informações repetidas entre os conjuntos comprometam a avaliação do modelo.

A normalização utilizada, identificada como norm-v1, aplica as seguintes operações:

- Normalização Unicode no formato NFC.
- Remoção de links iniciados por http://, https:// ou www..

- Remoção do marcador @user, sem distinção entre letras maiúsculas e minúsculas.
- Substituição de sequências de espaços e quebras de linha por espaços padronizados.
- Remoção de espaços no início e no final dos textos.
- Preservação de letras maiúsculas e minúsculas, pois o modelo utilizado diferencia essas características.

Além da normalização, o pipeline verifica textos vazios, duplicidades e divergências de classificação. Quando um mesmo texto normalizado aparece em conjuntos diferentes, são aplicadas regras para evitar vazamento de dados entre treinamento, validação e teste.

O conjunto de teste permanece inalterado e é utilizado apenas para detectar possíveis colisões durante essa verificação. As linhas removidas dos conjuntos de treinamento e validação são registradas em um arquivo específico de auditoria, sem modificar os arquivos CSV originais.

Os textos são tokenizados de acordo com o tokenizador associado ao modelo BERTimbau Base. O comprimento máximo configurado é de 128 tokens por sequência. Textos que ultrapassam esse limite são truncados, conforme a configuração do treinamento.

11.3 Modelos de IA Utilizados

Processamento de Linguagem Natural (PLN)

O projeto utiliza o modelo pré-treinado BERTimbau Base, disponibilizado pelo identificador neuralmind/bert-base-portuguese-cased. Trata-se de um modelo baseado na arquitetura BERT, pré-treinado em português brasileiro e adaptado, por meio de fine-tuning, para a tarefa de classificação de textos.

O modelo foi escolhido por ser adequado ao processamento de textos em português, ser compatível com as bibliotecas utilizadas no projeto e apresentar um custo computacional mais viável do que a versão Large para a execução em CPU.

A camada de classificação é configurada para produzir uma das três categorias definidas pelo projeto:

- seguro;
- suicidio;
- odio.

O treinamento é realizado com PyTorch e Transformers. A configuração oficial, identificada como nlp-v1, utiliza os seguintes parâmetros:

Parâmetros	**Configuração**
Modelo base	BERTimbau Base
Comprimento máximo	128 tokens
Número de épocas	3
Batch size de treinamento	16
Batch size de avaliação	32
Taxa de aprendizado	0,00002
Otimizador	AdamW (adamw_torch)
Weight decay	0,01
Warmup ratio	0,1
Agendador da taxa de aprendizado	Linear
Limite de norma do gradiente	1,0
Semente aleatória	42
Precisão mista FP16/BF16	Desativada
Ponderação das classes	Inversa da frequência

Tabela 6 – Exemplo de dados do projeto

Os pesos das classes são calculados pela fórmula:

$$\textbf{Peso da classe} = \frac{N}{K \times n^c}$$

Nessa expressão, N representa o número total de exemplos utilizados no treinamento, K representa a quantidade de classes e n^c representa a quantidade de exemplos da classe considerada. Essa estratégia aumenta a contribuição das classes menos frequentes para a função de perda.

11.4 Treinamento e Validação

Processamento de Linguagem Natural (PLN)

O treinamento consiste no ajuste dos parâmetros do BERTimbau Base para a classificação dos textos nas três categorias definidas. Durante esse processo, o modelo aprende padrões linguísticos presentes nos exemplos rotulados, utilizando a função de perda ponderada para considerar o desequilíbrio entre as classes.

O treinamento oficial registrado foi executado em CPU durante três épocas, totalizando 5.268 passos. A configuração efetivamente utilizada corresponde à configuração definida no arquivo nlp-v1.json, sem diferenças registradas entre os parâmetros configurados e os parâmetros efetivos.

Ao final de cada época, o desempenho é avaliado no conjunto de validação. A seleção do melhor checkpoint utiliza a métrica Macro F1, que calcula a média do F1-score das classes,

atribuindo a mesma importância a cada uma delas. Dessa forma, a seleção não depende exclusivamente do desempenho na classe majoritária.

O melhor resultado de validação foi registrado na terceira época, no checkpoint checkpoint-5268, com Macro F1 de aproximadamente 0,7995. Esse checkpoint foi reavaliado, e as métricas registradas foram consistentes com as métricas utilizadas na seleção.

Além do treinamento oficial, foi realizado um teste rápido identificado como nlp-v1-teste. Essa execução utilizou uma amostra reduzida de 192 textos para treinamento, 96 para validação e apenas uma época. Seu objetivo foi verificar o funcionamento do fluxo de treinamento, não substituir a avaliação do modelo oficial.

O conjunto de teste possui 6.027 textos. Entretanto, os metadados disponibilizados registram as métricas de validação do modelo oficial, não os resultados de uma avaliação final nesse conjunto de teste. Portanto, o desempenho no teste independente deve ser documentado após a execução e o registro dessa avaliação.

11.5 Métricas de Avaliação

Processamento de Linguagem Natural (PLN)

A avaliação do classificador utiliza métricas que permitem analisar tanto o desempenho geral quanto a capacidade de identificar cada uma das três categorias.

As principais métricas adotadas são:

- **Acurácia**: proporção de previsões corretas em relação ao total de exemplos avaliados.
- **Precisão**: proporção de previsões de determinada classe que realmente pertencem a essa classe.
- **Recall**: proporção de exemplos reais de determinada classe que foram identificados corretamente.
- **F1-score**: média harmônica entre precisão e revocação, permitindo avaliar o equilíbrio entre essas duas métricas.
- **Macro F1**: média dos F1-scores das classes, atribuindo o mesmo peso a cada categoria.
- **Matriz de confusão**: tabela que compara as classes reais com as classes previstas pelo modelo, permitindo observar acertos e confusões entre categorias.

Na avaliação oficial de validação, o modelo apresentou os seguintes resultados:

Métrica	**Resultado**
Acurácia	89,56%
Macro F1	79,95%
F1-score - seguro	93,83%
F1-score - suicídio	82,11%
F1-score — ódio	63,92%

Tabela 7 – Resultados da avaliação do modelo no conjunto de validação

Os resultados indicam um desempenho elevado na identificação de textos classificados como “seguro” e um F1-score de 82,11% para a classe “suicídio”. A classe “ódio” apresentou o menor F1-score, de 63,92%, indicando maior dificuldade de classificação nessa categoria.

A matriz de confusão da validação também permite observar que parte dos textos reais da classe “ódio” foi classificada como “seguro”. Esse comportamento evidencia a necessidade de acompanhar o desempenho individual das classes, em vez de considerar apenas a acurácia geral.

Os resultados apresentados nesta seção correspondem exclusivamente à validação do modelo oficial nlp-v1. O resultado do teste rápido, com Macro F1 de aproximadamente 32,41%, não é utilizado como medida final de desempenho, pois foi obtido com uma amostra reduzida e somente uma época de treinamento.

A avaliação final no conjunto de teste permanece como uma etapa necessária para verificar a capacidade de generalização do modelo em dados que não foram utilizados no treinamento nem na seleção do checkpoint.

12 TESTES E VALIDAÇÃO DO SISTEMA

Apresentar a estratégia de testes de software e os resultados obtidos.

13 GESTÃO DO PROJETO

Descrever a metodologia de desenvolvimento adotada (SCRUM), listar o Product Backlog, cronograma planejado inicial (SPRINTS) com tarefas e responsáveis, cronograma real final (SPRINTS) com tarefas e responsáveis.

14 RESULTADOS E DISCUSSÃO

Analisar os resultados obtidos, confrontando-os com os objetivos propostos.

Descrever quais as facilidades e as melhorias que o projeto traz aos usuários, quais os objetivos foram atendidos e quais objetivos não foram atendidos (e por que não foram atendidos?).

Fazer as considerações éticas, de privacidade e de impacto social. Discutir possíveis vieses, impactos sociais, questões éticas e conformidade com legislações de proteção de dados.

15 CONCLUSÃO E TRABALHOS FUTUROS

Apresentar as conclusões do projeto, limitações encontradas e sugestões de melhorias futuras.

16 ACEITE FINAL DO PROJETO

Elaborar um termo de aceite do projeto, pela comunidade externa.

17 REFERÊNCIAS

REFERÊNCIAS

SPRING. Spring Boot Reference Documentation. **Spring Framework Docs**, 2026. Disponível em: <https://docs.spring.io/spring-boot/docs/current/reference/html/>. Acesso em: 10 ago. 2026.