**PONTIFÍCIA UNIVERSIDADE CATÓLICA DE CAMPINAS**
**ENGENHARIA DE SOFTWARE**
**12563 - PROJETO INTEGRADOR VI - ENGENHARIA DE SOFTWARE**

# CLASSIFICAÇÃO INTELIGENTE DE CONTEÚDO WEB PARA CONTROLE DE ACESSO EM NAVEGADORES

**24002529 EDUARDA LUIZA PINHEIRO NEPOMUCENO**
**24008214 JEAN YUKI KIMURA**
**24014979 JHENIFER LAÍS BARBOSA**
**24019083 JOÃO PEDRO DUARTE GIATTI**

**ORIENTADORA: SÍLVIA CRISTINA DE MATOS SOARES**

**CAMPINAS**
**2º SEMESTRE DE 2026**

## RESUMO

O acesso frequente de crianças e adolescentes à internet por meio de computadores e navegadores torna relevante o desenvolvimento de mecanismos capazes de identificar e reduzir a exposição a conteúdos potencialmente inadequados. Neste semestre, este projeto propõe o desenvolvimento e a validação de um sistema executado em nível de máquina, associado ao uso de um navegador, capaz de obter o conteúdo textual e as imagens das páginas acessadas e submetê-los a modelos de inteligência artificial para classificação automática, seguindo dois caminhos técnicos complementares: processamento de linguagem natural, para o conteúdo textual, e visão computacional, para o conteúdo visual. Os modelos serão treinados ou ajustados (*fine-tuned*) pela equipe para classificar conteúdos em categorias previamente definidas, permitindo que um mecanismo de políticas consolide as classificações e determine se determinado conteúdo deve ser permitido ou bloqueado. O sistema também deverá registrar informações relevantes sobre as classificações e ações realizadas, de modo a possibilitar a apresentação de estatísticas e histórico por meio de uma interface de acompanhamento. O escopo deste semestre está concentrado na construção e validação dos motores de classificação textual e de imagem e de sua aplicação em nível de máquina, não contemplando ainda a implementação de um *gateway* de rede ou a identificação de usuários por endereço IP. Como evolução planejada para os semestres seguintes, o núcleo desenvolvido será integrado a uma infraestrutura baseada em Raspberry Pi, permitindo a aplicação centralizada de políticas a diferentes dispositivos de uma rede doméstica e, posteriormente, a expansão da solução para outros cenários de controle e segurança digital. Espera-se, ao final deste semestre, obter um protótipo funcional e mensurável, com suas métricas de desempenho e limitações técnicas devidamente documentadas.



**Palavras-chave**: Inteligência Artificial. Segurança digital. Controle parental. Classificação de conteúdo. Navegadores. Processamento de linguagem natural. Visão computacional.

**SUMÁRIO**


| | | |
|---|---|---|
| **1** | **INTRODUÇÃO** | **4** |
| **2** | **OBJETIVOS** | **7** |
| **2.1** | **Objetivo Geral** | **7** |
| **2.2** | **Objetivos Específicos** | **7** |
| **3** | **REPRESENTANTES DA COMUNIDADE EXTERNA** | **9** |
| **4** | **FUNDAMENTAÇÃO TEÓRICA** | **10** |
| **5** | **LEVANTAMENTO E ANÁLISE DE REQUISITOS** | **11** |
| **5.1** | **Requisitos Funcionais** | **11** |
| **5.2** | **Requisitos Não Funcionais** | **13** |
| **5.3** | **Requisitos Específicos para Inteligência Artificial** | **15** |
| **5.3.1** | **Modelo de Processamento de Linguagem Natural (Texto)** | **15** |
| **5.3.2** | **Modelo de Visão Computacional (Imagens)** | **16** |
| **5.3.3** | **Integração entre as Modalidades Textual e Visual** | **17** |
| **6** | **BENCHMARKING** | **19** |
| **7** | **DEFINIÇÃO DAS PERSONAS** | **21** |
| **7.1** | **Persona 1 – Renata Souza, a Mãe Vigilante** | **21** |
| **7.2** | **Persona 2 – Dona Marlene, Responsável por um Lar com Várias Crianças** | **22** |
| **7.3** | **Persona 3 – Caio "Modo Anônimo", o Adversário** | **23** |
| **8** | **PROTÓTIPOS DAS INTERFACES** | **24** |
| **9** | **MODELO DE DADOS** | **25** |
| **10** | **ARQUITETURA E TECNOLOGIAS** | **26** |
| **11** | **DESCRIÇÃO DA SOLUÇÃO TECNOLOGICA ATUAL DO PROJETO** | **27** |
| **11.1** | **Base de Dados** | **27** |
| **11.2** | **Pré-processamento dos Dados (se utilizar IA)** | **27** |
| **11.3** | **Modelos de IA Utilizados (se utilizar IA)** | **27** |
| **11.4** | **Treinamento e Validação (se utilizar IA)** | **27** |
| **11.5** | **Métricas de Avaliação (se utilizar IA)** | **27** |
| **11.6** | **Estrutura definida para Blockchain (se utilizar Blockchain)IA)** | **27** |
| **11.7** | **Definir se considera ataque ou defesa e como (se envolver Cibersegurança** | **27** |

**12 TESTES E VALIDAÇÃO DO SISTEMA . . . . . 28**

**13 GESTÃO DO PROJETO . . . . . 29**

**14 RESULTADOS E DISCUSSÃO . . . . . 30**

**15 CONCLUSÃO E TRABALHOS FUTUROS . . . . . 31**

**16 ACEITE FINAL DO PROJETO . . . . . 32**

**17 REFERÊNCIAS . . . . . 33**

**REFERÊNCIAS . . . . . 34**

# 1 INTRODUÇÃO

O acesso à internet por crianças e adolescentes ocorre, cada vez mais, por meio de navegadores instalados em computadores e outros dispositivos de uso pessoal. Embora a internet ofereça importantes recursos para educação, comunicação e entretenimento, a variedade e a velocidade de publicação de conteúdos também dificultam a identificação manual de materiais potencialmente inadequados.

As soluções tradicionais de controle de acesso frequentemente dependem de listas de bloqueio, categorias previamente cadastradas ou configurações realizadas individualmente em cada dispositivo. Essas abordagens podem apresentar limitações diante de páginas novas, conteúdos dinâmicos e situações em que um mesmo domínio disponibiliza materiais de naturezas distintas. Nesse contexto, técnicas de inteligência artificial podem ser utilizadas para analisar o conteúdo textual e o conteúdo visual (imagens) de uma página e estimar a quais categorias de conteúdo ela pertence, oferecendo uma camada adicional de decisão.

Este projeto tem como foco o desenvolvimento, neste semestre, de um sistema em nível de máquina voltado à análise do conteúdo textual e do conteúdo visual (imagens) de páginas acessadas por meio de um navegador. A proposta consiste em obter o conteúdo textual e as imagens disponíveis durante a navegação, submetê-los a modelos de inteligência artificial treinados ou ajustados pela equipe — um voltado ao texto e outro às imagens — e produzir classificações associadas a categorias previamente definidas. A partir dessas classificações, um mecanismo de políticas poderá determinar se o conteúdo deve ser permitido ou bloqueado de acordo com as regras estabelecidas para o cenário de uso.

A arquitetura proposta separa a responsabilidade de classificação da responsabilidade de decisão. Os modelos de inteligência artificial deverão responder à pergunta “que tipo de conteúdo está presente?” — cada um a partir de sua modalidade (texto ou imagem) —, enquanto o mecanismo de políticas deverá responder “esse conteúdo é permitido para este contexto?”, consolidando as classificações recebidas. Essa separação permite que as mesmas classificações sejam utilizadas por diferentes conjuntos de regras e possibilita a evolução posterior da solução para outros ambientes.

Para este semestre, o projeto seguirá dois caminhos técnicos complementares de inteligência artificial: a análise textual, com a utilização de técnicas de processamento de linguagem natural (PLN), e a análise visual, com a utilização de técnicas de visão computacional aplicadas às imagens presentes nas páginas. Os dois modelos serão treinados ou ajustados (*fine-tuned*) a partir de dados apropriados para as categorias definidas pela equipe. Suas avaliações serão realizadas por meio de métricas como precisão, *recall*, F1-*score*, taxas de falsos positivos e falsos negativos e tempo de classificação, permitindo medir não apenas a capacidade de classificação de cada modelo, mas também a viabilidade de sua utilização conjunta em um cenário de navegação.

O projeto também poderá disponibilizar uma interface de acompanhamento, na qual informações como classificações realizadas (textuais e de imagem), conteúdos bloqueados e

estatísticas de uso possam ser consultadas. Essa interface tem caráter de apoio ao acompanhamento e à avaliação do protótipo, não constituindo, neste semestre, um painel de administração de uma rede doméstica.

É importante delimitar o escopo desta etapa. O sistema desenvolvido terá como escopo: (i) um mecanismo em nível de máquina associado à navegação por navegador; (ii) a obtenção e o processamento do conteúdo textual e das imagens das páginas acessadas; (iii) um modelo de processamento de linguagem natural e um modelo de visão computacional, treinados ou ajustados pela equipe, para classificação do conteúdo textual e visual, respectivamente, em categorias definidas; (iv) um mecanismo de aplicação de políticas capaz de consolidar as classificações textual e de imagem e de permitir ou bloquear conteúdos de acordo com elas; e (v) o registro e a apresentação de informações necessárias para testes, validação e acompanhamento do sistema.

Não fazem parte do escopo deste semestre: a implementação do Raspberry Pi como *gateway* de rede; a identificação de usuários ou dispositivos por endereço IP em nível de rede; a aplicação centralizada de políticas para múltiplos dispositivos; e a análise do tráfego criptografado ponto a ponto. Também não se pretende garantir o bloqueio absoluto de todo conteúdo inadequado presente na internet. A solução será apresentada como um mecanismo de redução da exposição a conteúdos potencialmente inadequados, considerando as limitações inerentes à obtenção de conteúdo textual e de imagens, ao funcionamento dos navegadores, ao uso de HTTPS e à natureza dinâmica da web.

**Evolução planejada do projeto**

A solução desenvolvida neste semestre constitui o núcleo inicial de uma proposta de maior abrangência para os semestres seguintes. Como evolução planejada, os motores de classificação textual e de imagem deverão ser integrados a uma infraestrutura baseada em Raspberry Pi, que atuará como ponto central de controle em uma rede doméstica. Nessa etapa futura, será possível associar dispositivos e, posteriormente, usuários ou perfis a políticas específicas e aplicar as decisões de acesso de maneira centralizada.

Em uma etapa posterior, a solução poderá incorporar um painel administrativo voltado a responsáveis, permitindo configurar perfis, políticas e horários, além de acompanhar estatísticas e tentativas de acesso bloqueadas. A arquitetura também poderá ser expandida para cenários além do controle parental, como ambientes educacionais e empresariais, nos quais a classificação inteligente de conteúdo possa auxiliar na redução de riscos de segurança digital.

**Círculo Dourado**

Para explicitar o propósito do projeto, aplica-se o modelo do Círculo Dourado (*Golden Circle*), de Simon Sinek, estruturado em três camadas: *Why* (por quê), *How* (como) e *What* (o quê).

a) **Why (Por quê):** Acreditamos que responsáveis devem possuir meios acessíveis de reduzir a exposição de crianças e adolescentes a conteúdos potencialmente inadequados na internet, sem depender exclusivamente de listas estáticas de bloqueio ou de configurações técnicas complexas.

b) **How (Como):** Neste semestre, isso será investigado por meio de um sistema em nível de máquina capaz de analisar o conteúdo textual e o conteúdo visual (imagens) de páginas acessadas no navegador, utilizando um modelo de processamento de linguagem natural e um modelo de visão computacional, treinados ou ajustados pela equipe, para classificá-los segundo categorias previamente definidas. As classificações serão então consolidadas e utilizadas por um mecanismo de políticas para determinar a ação de acesso.

c) **What (O quê):** O resultado deste semestre será um protótipo funcional de classificação e controle de conteúdo textual e visual em nível de máquina, acompanhado de métricas de avaliação de cada modalidade e, quando aplicável, uma interface para acompanhamento das classificações e bloqueios. Nos semestres seguintes, esse núcleo será integrado a uma infraestrutura de rede baseada em Raspberry Pi, com o objetivo de evoluir para uma solução centralizada de controle de acesso.

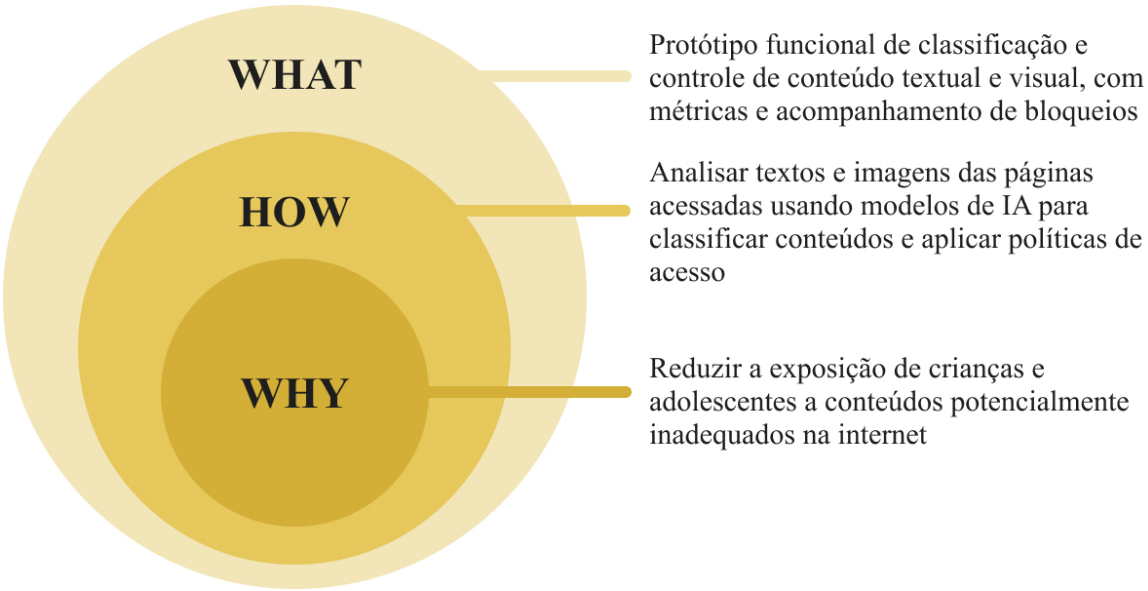



Figura 1 – Círculo Dourado

# 2 OBJETIVOS

## 2.1 Objetivo Geral

Desenvolver e validar um protótipo em nível de máquina capaz de analisar o conteúdo textual e o conteúdo visual (imagens) de páginas acessadas por meio de um navegador, utilizando um modelo de processamento de linguagem natural e um modelo de visão computacional, treinados ou ajustados (*fine-tuned*) pela equipe, para classificar conteúdos em categorias previamente definidas e aplicar políticas de permissão ou bloqueio a partir da consolidação dessas classificações.

## 2.2 Objetivos Específicos

a) Pesquisar e selecionar técnicas de processamento de linguagem natural e de visão computacional, bem como modelos de inteligência artificial adequados à classificação de conteúdo textual e visual de páginas web, considerando as restrições de execução e resposta esperadas para um sistema em nível de máquina;

b) Construir, preparar e documentar bases de dados (textual e de imagens) para treinamento, validação e teste dos modelos, definindo categorias de conteúdo e procedimentos de pré-processamento compatíveis com cada modalidade;

c) Treinar ou ajustar (*fine-tune*) um modelo de processamento de linguagem natural e um modelo de visão computacional para classificar, respectivamente, o conteúdo textual e as imagens das páginas nas categorias definidas, buscando reduzir a dependência de listas estáticas de sites;

d) Desenvolver o mecanismo em nível de máquina responsável por obter o conteúdo textual e as imagens das páginas acessadas pelo navegador e encaminhá-los aos respectivos classificadores, respeitando as limitações técnicas impostas pelo funcionamento da web e pelo uso de conexões criptografadas;

e) Desenvolver um mecanismo de políticas que utilize e consolide as classificações textual e de imagem produzidas pela inteligência artificial para determinar se determinado conteúdo deve ser permitido ou bloqueado, mantendo separadas as responsabilidades de classificação e decisão;

f) Implementar, quando aplicável ao protótipo, uma interface de acompanhamento das classificações e ações realizadas, permitindo visualizar informações como conteúdos analisados (por modalidade), bloqueios e estatísticas de uso;

g) Avaliar o desempenho dos classificadores textual e de imagem por meio de métricas como precisão, *recall*, F1-*score*, taxa de falsos positivos, taxa de falsos negativos e

tempo de classificação, analisando os resultados obtidos, isoladamente e em conjunto, e suas limitações;

h) Realizar testes do sistema em diferentes situações de navegação, verificando a integração entre obtenção do conteúdo textual e visual, classificação, consolidação das classificações, aplicação das políticas e registro dos resultados;

i) Identificar e documentar as limitações técnicas, éticas e de privacidade da solução, especialmente aquelas relacionadas ao monitoramento de navegação, à obtenção de conteúdo textual e de imagens, à classificação automatizada e ao uso de dados de navegação;

j) Estabelecer uma base arquitetural que permita, nos semestres seguintes, a integração dos motores de classificação textual e de imagem a uma infraestrutura de rede baseada em Raspberry Pi e a evolução da solução para aplicação centralizada de políticas em múltiplos dispositivos.

## 3 REPRESENTANTES DA COMUNIDADE EXTERNA

Caracterizar a extensão (62 horas de extensão) - são as pessoas que participarão da definição, das entrevistas, da definição dos requisitos, da validação dos protótipos e da validação final do projeto).

Nome, contato (e-mail) e cargo do profissional/pessoa e o nome e CNPJ da organização onde ele(a) atua (2 a 5 profissionais).

# 4 FUNDAMENTAÇÃO TEÓRICA

Apresentar os conceitos teóricos relacionados à tecnologia atual e Engenharia de Software que embasam o projeto.

Incluir a definição das técnicas/ferramentas/algoritmos etc. das tecnologias atuais utilizadas.

# 5 LEVANTAMENTO E ANÁLISE DE REQUISITOS

Os requisitos apresentados a seguir foram derivados do escopo definido para este semestre (Capítulo 1) e serão validados junto aos representantes da comunidade externa (Capítulo 3). Cada requisito recebe um código único e uma prioridade, classificada segundo a técnica MoSCoW em: **Essencial** (indispensável para o protótipo deste semestre), **Importante** (deve ser entregue, mas admite solução simplificada) e **Desejável** (agrega valor, mas pode ser postergado para semestres futuros).

O projeto adota, neste semestre, **dois caminhos técnicos complementares de inteligência artificial**: (i) a análise do **conteúdo textual** das páginas, por meio de técnicas de processamento de linguagem natural (PLN); e (ii) a análise do **conteúdo visual** (imagens) presente nas páginas, por meio de técnicas de visão computacional. Os dois modelos operam de forma independente sobre suas respectivas modalidades de entrada e têm suas saídas consolidadas pelo mecanismo de políticas, que utiliza as classificações textual e de imagem para decidir se o conteúdo deve ser permitido ou bloqueado. Essa divisão está refletida nos requisitos funcionais, não funcionais e específicos de inteligência artificial apresentados a seguir.

## 5.1 Requisitos Funcionais

Os requisitos funcionais descrevem as capacidades que o sistema deve oferecer, cobrindo o fluxo completo de obtenção do conteúdo textual e do conteúdo visual (imagens), classificação por PLN e por visão computacional, consolidação dos resultados, aplicação de políticas e acompanhamento pelo usuário.

| Código | Descrição | Prioridade |
|---|---|---|
| RF01 | O sistema deve obter o conteúdo textual das páginas acessadas pelo navegador durante a navegação do usuário. | Essencial |
| RF02 | O sistema deve pré-processar o conteúdo textual obtido (limpeza, normalização, remoção de ruído) antes de submetê-lo ao classificador. | Essencial |
| RF03 | O sistema deve submeter o conteúdo textual pré-processado ao modelo de processamento de linguagem natural (PLN) para classificação em categorias previamente definidas. | Essencial |
| RF04 | O sistema deve associar a cada classificação textual um nível de confiança (*score*) atribuído pelo modelo de PLN. | Essencial |
| RF05 | O sistema deve aplicar um mecanismo de políticas que determine, a partir das classificações textual e de imagem recebidas, se o conteúdo deve ser permitido ou bloqueado. | Essencial |

| Código | Descrição | Prioridade |
|---|---|---|
| RF06 | O sistema deve permitir a configuração de regras de política por categoria de conteúdo (permitir, bloquear ou alertar). | Importante |
| RF07 | O sistema deve bloquear o acesso ao conteúdo e exibir uma mensagem informativa ao usuário quando a política determinar o bloqueio. | Essencial |
| RF08 | O sistema deve registrar (log) cada classificação realizada, incluindo URL/domínio, modalidade (texto e/ou imagem), categoria atribuída, nível de confiança, ação tomada e data/hora. | Essencial |
| RF09 | O sistema deve disponibilizar uma interface de acompanhamento para consulta do histórico de classificações e bloqueios realizados. | Importante |
| RF10 | O sistema deve apresentar estatísticas de uso na interface de acompanhamento (ex.: total de páginas analisadas, distribuição por categoria, percentual bloqueado por modalidade, período consultado). | Importante |
| RF11 | O sistema deve permitir que o usuário/responsável inicie ou pause o monitoramento em nível de máquina. | Importante |
| RF12 | O sistema deve tratar páginas das quais não seja possível extrair conteúdo textual e/ou imagens em quantidade suficiente, aplicando uma política padrão definida pela equipe. | Importante |
| RF13 | O sistema deve permitir a atualização independente das versões dos modelos de classificação (textual e de imagem) sem exigir reinstalação completa do sistema. | Desejável |
| RF14 | O sistema deve obter as imagens presentes nas páginas acessadas pelo navegador durante a navegação do usuário. | Essencial |
| RF15 | O sistema deve pré-processar as imagens obtidas (redimensionamento, normalização e descarte de elementos irrelevantes, como ícones e imagens de interface) antes de submetê-las ao classificador de visão computacional. | Essencial |
| RF16 | O sistema deve submeter as imagens pré-processadas a um modelo de visão computacional para classificação em categorias previamente definidas. | Essencial |
| RF17 | O sistema deve associar a cada classificação de imagem um nível de confiança (*score*) atribuído pelo modelo de visão computacional. | Essencial |

| Código | Descrição | Prioridade |
|---|---|---|
| RF18 | O sistema deve consolidar as classificações textual e de imagem de uma mesma página em uma decisão única a ser utilizada pelo mecanismo de políticas, definindo um critério de precedência para os casos em que as duas classificações divergirem. | Essencial |

Tabela 1 – Requisitos Funcionais

## 5.2 Requisitos Não Funcionais

Os requisitos não funcionais descrevem atributos de qualidade do sistema, organizados a partir de categorias inspiradas na norma ISO/IEC 25010.

| Código | Categoria | Descrição | Prioridade |
|---|---|---|---|
| RNF01 | Desempenho | A classificação textual e a classificação de imagem de uma página devem ser concluídas em tempo compatível com a experiência de navegação, com metas numéricas a serem validadas experimentalmente durante a avaliação dos modelos (ver RIA05 e RIC05). | Essencial |
| RNF02 | Desempenho | O sistema deve operar em nível de máquina com consumo de CPU, memória e (quando aplicável) GPU compatível com o uso doméstico, sem degradar de forma perceptível o desempenho do computador, mesmo executando os módulos de PLN e de visão computacional em conjunto. | Importante |
| RNF03 | Segurança | O conteúdo textual, as imagens coletadas e os registros de navegação armazenados localmente devem ser protegidos contra acesso não autorizado (ex.: permissões de arquivo restritas). | Essencial |
| RNF04 | Privacidade | O sistema não deve transmitir o conteúdo textual e as imagens coletados a servidores externos sem consentimento explícito, priorizando processamento local quando viável. | Essencial |

| Código | Categoria | Descrição | Prioridade |
|---|---|---|---|
| RNF05 | Privacidade | O sistema deve minimizar a coleta e a retenção de dados de navegação (textuais e de imagem) ao estritamente necessário para classificação, auditoria e apresentação de estatísticas, em conformidade com a LGPD. | Essencial |
| RNF06 | Usabilidade | A interface de acompanhamento deve apresentar as informações de forma clara e compreensível para usuários sem conhecimento técnico avançado. | Importante |
| RNF07 | Confiabilidade | O sistema deve continuar operando em modo degradado (ex.: aplicando uma política padrão) em caso de falha de qualquer um dos módulos de classificação (textual ou de imagem), evitando bloquear indevidamente toda a navegação. | Importante |
| RNF08 | Manutenibilidade | A arquitetura deve manter separadas as responsabilidades de classificação textual (PLN), classificação de imagem (visão computacional) e de aplicação de políticas, permitindo evolução e substituição independente de cada módulo. | Essencial |
| RNF09 | Escalabilidade | O sistema deve ser projetado de modo a permitir, em semestres futuros, sua integração a uma infraestrutura baseada em Raspberry Pi sem redesenho dos motores de classificação textual e de imagem. | Importante |
| RNF10 | Compatibilidade | O sistema deve ser compatível com pelo menos um navegador amplamente utilizado (a definir pela equipe, ex.: Chrome/Chromium ou Firefox). | Essencial |
| RNF11 | Auditabilidade | Todos os registros de log gerados devem ser íntegros e rastreáveis, permitindo auditoria posterior das decisões tomadas pelo sistema. | Importante |

Tabela 2 – Requisitos Não Funcionais

## 5.3 Requisitos Específicos para Inteligência Artificial

Os requisitos a seguir definem critérios de qualidade e de processo específicos dos modelos de inteligência artificial, complementando os requisitos funcionais e não funcionais já apresentados. Como o projeto adota dois caminhos técnicos complementares, os requisitos estão organizados em três grupos: os específicos do modelo de **processamento de linguagem natural** (texto), os específicos do modelo de **visão computacional** (imagens) e os relativos à **integração** entre as duas modalidades. Os valores numéricos indicados como *a definir* deverão ser fixados pela equipe em conjunto com a orientadora, a partir dos primeiros experimentos com as bases de dados construídas (Capítulo 11).

### 5.3.1 Modelo de Processamento de Linguagem Natural (Texto)

| Código | Descrição | Prioridade |
|---|---|---|
| RIA01 | O modelo de PLN deve atingir acurácia mínima de *X%* (a definir) no conjunto de teste, considerando as categorias de conteúdo estabelecidas pela equipe. | Essencial |
| RIA02 | O modelo deve atingir F1-*score* mínimo de *X* (a definir) por categoria, priorizando o *recall* nas categorias de conteúdo sensível. | Essencial |
| RIA03 | A taxa de falsos negativos para categorias sensíveis (conteúdo potencialmente inadequado) deve ser inferior a *X%* (a definir), priorizando a redução de exposição em detrimento de bloqueios excessivos. | Essencial |
| RIA04 | A taxa de falsos positivos deve ser mantida abaixo de *X%* (a definir), de modo a preservar a usabilidade do sistema e evitar bloqueios indevidos de conteúdo legítimo. | Importante |
| RIA05 | O tempo de inferência do modelo para o texto de uma única página deve ser inferior a *X* milissegundos/segundos (a definir), em hardware de referência estabelecido pela equipe. | Essencial |
| RIA06 | O modelo deve ser treinado ou ajustado (*fine-tuned*) a partir de uma base de dados textual rotulada, documentada quanto à origem, ao volume e à distribuição entre categorias. | Essencial |
| RIA07 | O processo de treinamento deve utilizar conjuntos distintos de treino, validação e teste, evitando vazamento de dados (*data leakage*) entre eles. | Essencial |

| Código | Descrição | Prioridade |
|---|---|---|
| RIA08 | O modelo utilizado em cada classificação textual registrada deve ser identificável por versão, permitindo rastrear qual versão gerou determinado resultado. | Importante |
| RIA09 | O sistema deve registrar o nível de confiança (*score*) de cada classificação textual, possibilitando a definição de limiares (*thresholds*) distintos por categoria no mecanismo de políticas. | Importante |
| RIA10 | O desempenho do modelo diante de conteúdos ambíguos ou com pouco texto disponível deve ser avaliado e documentado, junto às limitações identificadas. | Importante |
| RIA11 | O sistema deve permitir a reavaliação periódica do modelo de PLN com novos dados, sem comprometer a disponibilidade do mecanismo de classificação durante a atualização. | Desejável |

Tabela 3 – Requisitos Específicos do Modelo de Processamento de Linguagem Natural

### 5.3.2 Modelo de Visão Computacional (Imagens)

| Código | Descrição | Prioridade |
|---|---|---|
| RIC01 | O modelo de visão computacional deve atingir acurácia mínima de *X%* (a definir) no conjunto de teste, considerando as categorias de conteúdo estabelecidas pela equipe. | Essencial |
| RIC02 | O modelo deve atingir F1-*score* mínimo de *X* (a definir) por categoria, priorizando o *recall* nas categorias de conteúdo visual sensível. | Essencial |
| RIC03 | A taxa de falsos negativos para categorias sensíveis (imagens potencialmente inadequadas) deve ser inferior a *X%* (a definir), priorizando a redução de exposição em detrimento de bloqueios excessivos. | Essencial |
| RIC04 | A taxa de falsos positivos deve ser mantida abaixo de *X%* (a definir), de modo a preservar a usabilidade do sistema e evitar bloqueios indevidos de imagens legítimas. | Importante |
| RIC05 | O tempo de inferência do modelo para uma única imagem deve ser inferior a *X* milissegundos/segundos (a definir), em hardware de referência estabelecido pela equipe. | Essencial |

| Código | Descrição | Prioridade |
|---|---|---|
| RIC06 | O modelo deve ser treinado ou ajustado (*fine-tuned*) a partir de uma base de dados de imagens rotulada, documentada quanto à origem, ao volume e à distribuição entre categorias. | Essencial |
| RIC07 | O processo de treinamento deve utilizar conjuntos distintos de treino, validação e teste, evitando vazamento de dados (*data leakage*) entre eles. | Essencial |
| RIC08 | O modelo utilizado em cada classificação de imagem registrada deve ser identificável por versão, permitindo rastrear qual versão gerou determinado resultado. | Importante |
| RIC09 | O sistema deve registrar o nível de confiança (*score*) de cada classificação de imagem, possibilitando a definição de limiares (*thresholds*) distintos por categoria no mecanismo de políticas. | Importante |
| RIC10 | O desempenho do modelo diante de imagens de baixa resolução, parcialmente carregadas ou de conteúdo ambíguo deve ser avaliado e documentado, junto às limitações identificadas. | Importante |
| RIC11 | O sistema deve permitir a reavaliação periódica do modelo de visão computacional com novos dados, sem comprometer a disponibilidade do mecanismo de classificação durante a atualização. | Desejável |

Tabela 4 – Requisitos Específicos do Modelo de Visão Computacional

### 5.3.3 Integração entre as Modalidades Textual e Visual

| Código | Descrição | Prioridade |
|---|---|---|
| RIM01 | A equipe deve definir e documentar o critério de consolidação (ex.: predomínio da categoria mais restritiva, combinação ponderada dos *scores*) utilizado quando as classificações textual e de imagem de uma mesma página divergirem. | Essencial |
| RIM02 | O sistema deve continuar operando e produzindo uma decisão de política válida quando apenas uma das modalidades (texto ou imagem) estiver disponível para uma página (ex.: página sem imagens relevantes ou sem texto suficiente). | Importante |

| Código | Descrição | Prioridade |
|---|---|---|
| RIM03 | A avaliação do sistema deve reportar, além das métricas de cada modelo isoladamente, o impacto da combinação das duas modalidades sobre a acurácia e as taxas de falsos positivos/negativos da decisão final. | Importante |

Tabela 5 – Requisitos de Integração entre PLN e Visão Computacional

# 6 BENCHMARKING

O benchmarking compara o ORCA com três soluções de controle parental disponíveis no mercado: Qustodio, Microsoft Family Safety e Net Nanny. A comparação considera funcionalidades de filtragem, análise de conteúdo, aplicação de regras, monitoramento e características técnicas relacionadas aos objetivos do projeto. O objetivo não é afirmar que o ORCA apresenta mais recursos que as soluções existentes, mas identificar diferenças entre as abordagens adotadas e a proposta técnica desenvolvida neste projeto.

| **Funcionalidade** | **ORCA** | **Qustodio** | **Microsoft Family Safety** | **Net Nanny** |
|---|---|---|---|---|
| Filtragem de sites por categorias | ✓ | ✓ | ✓ | ✓ |
| Análise contextual do conteúdo textual em tempo real | ✓ | – | X | ✓ |
| Modelo de processamento de linguagem natural treinado ou ajustado pela equipe | ✓ | X | X | X |
| Classificação de imagens por modelo de visão computacional | ✓ | – | – | – |
| Modelo de visão computacional treinado ou ajustado pela equipe | ✓ | X | X | X |
| Mecanismo próprio para consolidar classificações textuais e visuais | ✓ | X | X | X |
| Regras para permitir ou bloquear conteúdo | ✓ | ✓ | ✓ | ✓ |
| Bloqueio de sites específicos | ✓ | ✓ | ✓ | ✓ |
| Controle de tempo de tela e uso de aplicativos | X | ✓ | ✓ | ✓ |
| Histórico ou relatórios de atividade | ✓ | ✓ | ✓ | ✓ |
| Avaliação dos classificadores por métricas de desempenho | ✓ | X | X | X |
| Controle centralizado por gateway Raspberry Pi | X | – | X | X |

Tabela 6 – Comparativo entre o ORCA e soluções de controle parental do mercado.

O principal diferencial técnico do ORCA é a proposta de combinar dois classificadores de inteligência artificial: um baseado em processamento de linguagem natural (PLN), voltado à análise do conteúdo textual, e outro baseado em visão computacional, voltado à classificação das imagens presentes nas páginas acessadas pelo navegador. Os modelos serão treinados ou ajustados pela equipe com bases de dados preparadas para as categorias definidas no projeto. Como

as soluções comerciais podem utilizar tecnologias proprietárias, a ausência de documentação pública sobre uma técnica específica não significa que ela não seja utilizada internamente; por isso, os campos sem confirmação foram indicados com um traço.

Outra característica da proposta é a separação entre classificação e decisão. Os classificadores deverão identificar as categorias presentes no texto e nas imagens, enquanto um mecanismo de políticas consolidará os resultados e determinará se o conteúdo deve ser permitido ou bloqueado. Essa arquitetura será avaliada por meio de métricas como precisão, recall, F1-score, taxas de falsos positivos e falsos negativos e tempo de classificação.

As soluções analisadas também oferecem funcionalidades que não fazem parte do escopo atual do ORCA, como controle de tempo de tela e uso de aplicativos. Além disso, a aplicação centralizada de políticas por meio de um gateway Raspberry Pi é uma evolução planejada para os próximos semestres, e não uma funcionalidade prevista para o protótipo deste semestre. Dessa forma, o benchmarking evidencia tanto as capacidades que o ORCA pretende investigar quanto os limites de seu escopo em relação às ferramentas existentes.

# 7 DEFINIÇÃO DAS PERSONAS

## 7.1 Persona 1 – Renata Souza, a Mãe Vigilante



- **Nome:** Renata Souza
- **Idade:** 38 anos
- **Sexo:** Feminino
- **Estado Civil:** Casada
- **Ocupação/Trabalho:** Analista financeira, trabalha em regime híbrido (*home office* 3x por semana)
- **Biografia:** Atua na área financeira e gerencia a rotina familiar. Mãe de Lucas (8) e Beatriz (12); o notebook do trabalho e o tablet da casa são compartilhados pelos filhos fora do horário escolar.
- **Hobbies:** Leitura, jardinagem e passar tempo em família.
- **Conhecimento em tecnologia:** Médio.
- **Conhecimento no domínio do negócio:** Alto.
- **Dispositivos que mais utiliza:** Notebook e celular.
- **Objetivos dentro do sistema:** Ter tranquilidade para trabalhar sem precisar ficar ao lado das crianças durante a navegação, entendendo de forma simples quais tipos de conteúdo os filhos estão encontrando e confiando que o sistema toma decisões corretas.
- **Motivos para utilizar o sistema:** Soluções de controle parental tradicionais são complexas ou geram alertas em excesso. O sistema oferece transparência, facilidade de uso e redução de falsos positivos em conteúdos escolares.

### 7.2 Persona 2 – Dona Marlene, Responsável por um Lar com Várias Crianças



- **Nome:** Marlene da Silva (Dona Marlene)
- **Idade:** 58 anos
- **Sexo:** Feminino
- **Estado Civil:** Viúva
- **Ocupação/Trabalho:** Aposentada; cuida informalmente dos netos e sobrinhos-netos enquanto os pais trabalham
- **Biografia:** Funciona como uma espécie de "creche familiar", recebendo em casa até 5 crianças com idades entre 6 e 14 anos em horários distintos, contando com um único computador e um tablet compartilhados.
- **Hobbies:** Tricô, culinária e cuidar das plantas.
- **Conhecimento em tecnologia:** Baixo.
- **Conhecimento no domínio do negócio:** Médio.
- **Dispositivos que mais utiliza:** Computador de mesa compartilhado.
- **Objetivos dentro do sistema:** Um sistema que funcione no "piloto automático", sem exigir troca de perfil a cada criança, garantindo proteção consistente sem configurações complexas.
- **Motivos para utilizar o sistema:** Necessidade de proteção automática em dispositivos compartilhados por crianças de diferentes faixas etárias, sem exigir conhecimentos técnicos avançados de sua parte.

### 7.3 Persona 3 – Caio “Modo Anônimo”, o Adversário



- **Nome:** Caio Mendes
- **Idade:** 13 anos
- **Sexo:** Masculino
- **Estado Civil:** Solteiro (Estudante)
- **Ocupação/Trabalho:** Estudante do 8º ano
- **Biografia:** Autoproclamado “especialista em TI” da família. Usa o tablet da casa compartilhado com os pais e irmão mais novo; já alterou configurações de rede por curiosidade para testar limites.
- **Hobbies:** Jogos eletrônicos, vídeos de tecnologia e exploração de softwares.
- **Conhecimento em tecnologia:** Alto para a idade.
- **Conhecimento no domínio do negócio:** Baixo.
- **Dispositivos que mais utiliza:** Tablet e smartphone.
- **Objetivos dentro do sistema:** Acessar conteúdo sem restrição por curiosidade ou para testar os limites do sistema, entendendo como a ferramenta decide o que bloquear.
- **Motivos para testar o sistema:** Representa o caso de uso adversarial essencial para validar os requisitos de segurança, integridade de registros e robustez da arquitetura de IA.

# 8 PROTÓTIPOS DAS INTERFACES

Print, legível, das interfaces, no arquivo do relatório final .docx e também o link do software utilizado para o design (ex: link do figma, XD etc.).

Não será aceito apenas o link.

Validação/aceite dos protótipos com as pessoas/profissionais da comunidade externa.

# 9 MODELO DE DADOS

MER para banco de dados relacional ou modelo da estrutura de dados para banco de dados não relacional.

# 10 ARQUITETURA E TECNOLOGIAS

Descrever a arquitetura geral do sistema, incluindo o diagrama/modelo arquitetural e a integração dos componentes de IA e/ou demais tecnologias atuais do projeto.

Descrever as tecnologias, linguagens, frameworks e bibliotecas utilizadas no desenvolvimento do sistema (frontend, protótipos, backend, banco de dados, cloud etc).

# 11 DESCRIÇÃO DA SOLUÇÃO TECNOLOGICA ATUAL DO PROJETO

## 11.1 Base de Dados

Descrever a origem, características, volume e tratamento dos dados utilizados.

## 11.2 Pré-processamento dos Dados (se utilizar IA)

Explicar as técnicas de limpeza, normalização e preparação dos dados.

## 11.3 Modelos de IA Utilizados (se utilizar IA)

Descrever os algoritmos, modelos e hiperparâmetros adotados.

## 11.4 Treinamento e Validação (se utilizar IA)

Explicar o processo de treinamento, validação e teste dos modelos.

## 11.5 Métricas de Avaliação (se utilizar IA)

Apresentar e justificar as métricas utilizadas para avaliação do desempenho.

## 11.6 Estrutura definida para Blockchain (se utilizar Blockchain)IA)

Apresentar e justificar a estrutura e seus relacionamentos definidos para Blockchain.

## 11.7 Definir se considera ataque ou defesa e como (se envolver Cibersegurança

Apresentar e justificar se o projeto envolve mecanismos para ataque e/ou defesa p/ Cibersegurança.

# 12 TESTES E VALIDAÇÃO DO SISTEMA

Apresentar a estratégia de testes de software e os resultados obtidos.

# 13 GESTÃO DO PROJETO

Descrever a metodologia de desenvolvimento adotada (SCRUM), listar o Product Backlog, cronograma planejado inicial (SPRINTS) com tarefas e responsáveis, cronograma real final (SPRINTS) com tarefas e responsáveis.

# 14 RESULTADOS E DISCUSSÃO

Analisar os resultados obtidos, confrontando-os com os objetivos propostos.

Descrever quais as facilidades e as melhorias que o projeto traz aos usuários, quais os objetivos foram atendidos e quais objetivos não foram atendidos (e por que não foram atendidos?).

Fazer as considerações éticas, de privacidade e de impacto social. Discutir possíveis vieses, impactos sociais, questões éticas e conformidade com legislações de proteção de dados.

# 15 CONCLUSÃO E TRABALHOS FUTUROS

Apresentar as conclusões do projeto, limitações encontradas e sugestões de melhorias futuras.

## 16 ACEITE FINAL DO PROJETO

Elaborar um termo de aceite do projeto, pela comunidade externa.

# 17 REFERÊNCIAS

# REFERÊNCIAS

SPRING. Spring Boot Reference Documentation. **Spring Framework Docs**, 2026. Disponível em: <https://docs.spring.io/spring-boot/docs/current/reference/html/>. Acesso em: 10 ago. 2026.